TECH CHALLENGE – FASE 2

- Classificação da Qualidade de Vinhos com Machine Learning
- Aluna: Cibele Dinorah dos Reis

PROBLEMA DE NEGÓCIO

- A avaliação da qualidade do vinho é subjetiva.
- O objetivo é prever a qualidade a partir de características físico-química

O DATASET

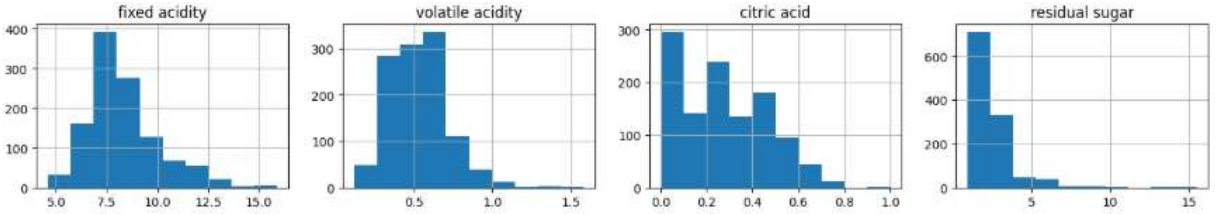
- Fonte: Wine Quality Dataset (Kaggle)
- Quantidade de registros
- Variáveis disponíveis
  - Acidez
  - pH
  - Álcool
  - Sulfatos
  - Densidade, entre outros.

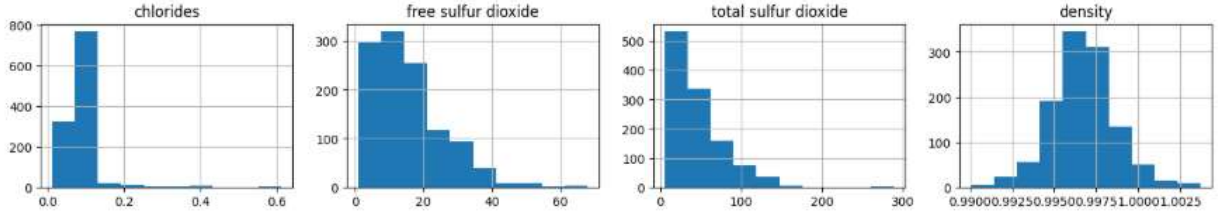
TRANSFORMAÇÃO DA VARIÁVEL ALVO

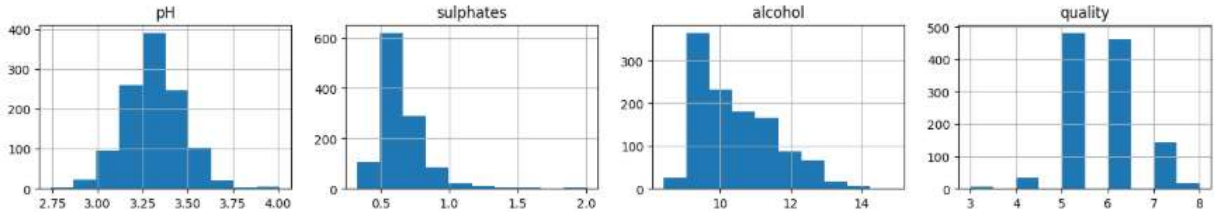
- Alta Qualidade = nota ≥ 7
- Baixa/Média Qualidade = nota < 7

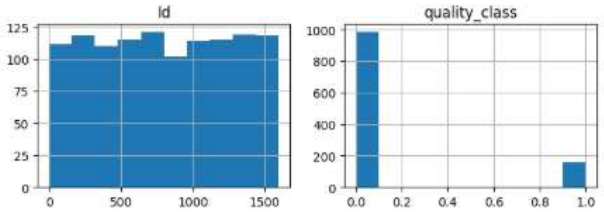
Transformação Binária

DISTRIBUIÇÃO DAS VARIÁVEIS

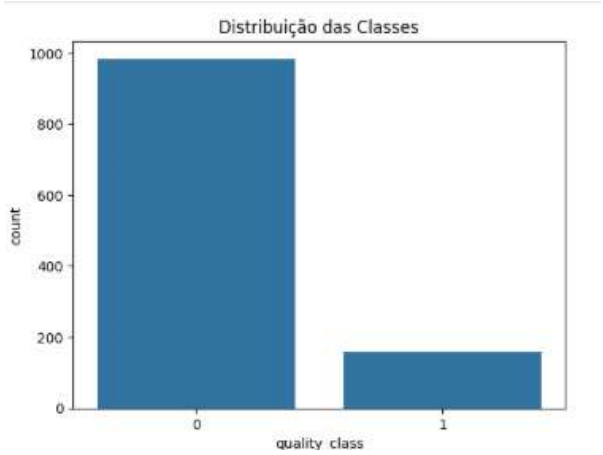








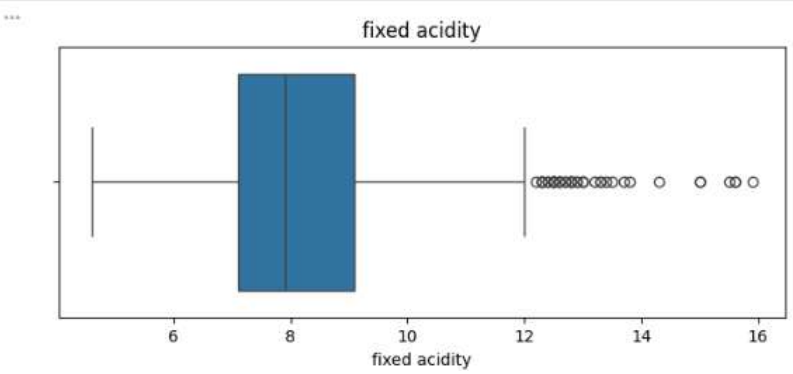
DISTRIBUIÇÃO DAS CLASSES

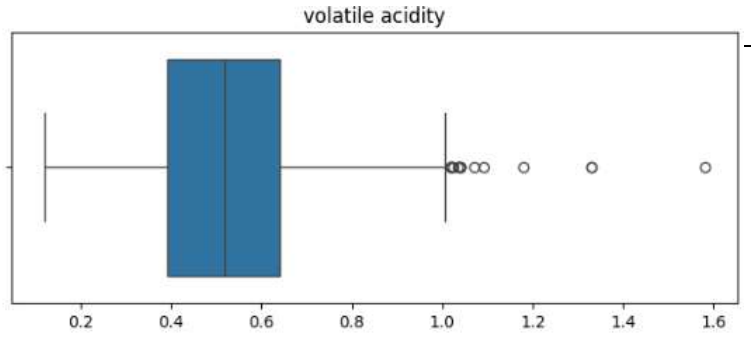


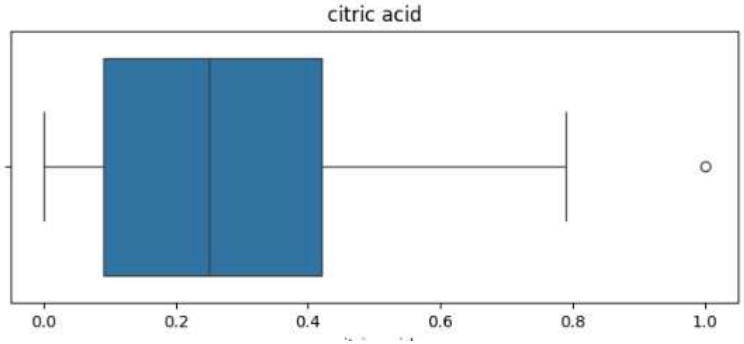
Este gráfico evidencia o desbalanço das classes. Aproximadamente 980 amostras estão classificadas como: **0-**“Baixa”, “Média” qualidade.

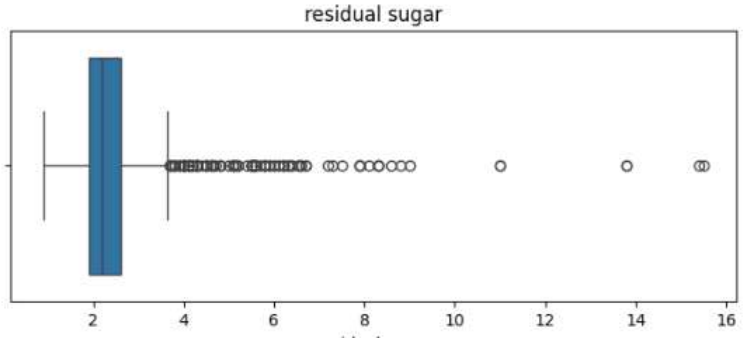
No outro extremo, há um aproximado de 160 amostras classificadas como **1-** “Alta Qualidade”

IDENTIFICAÇÃO DE *OUTLIERS*

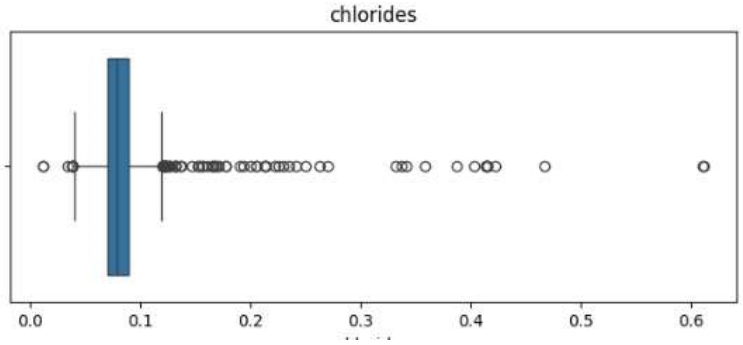


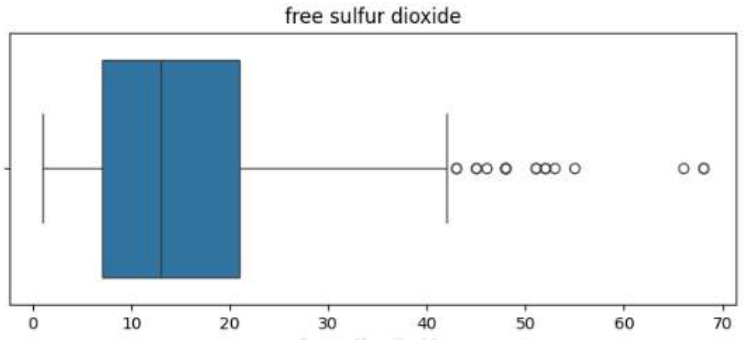


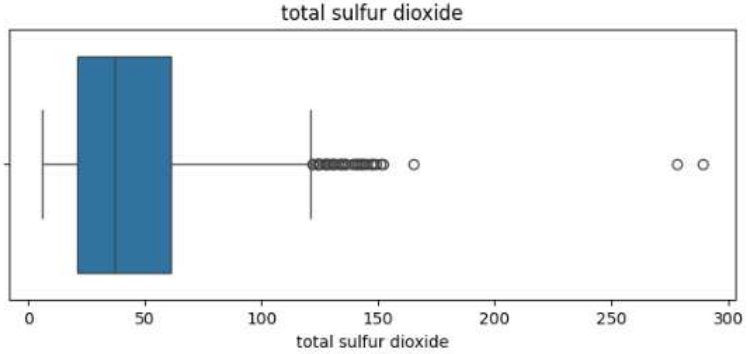


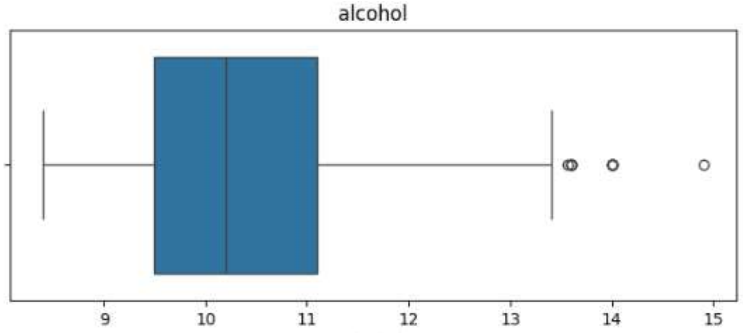


IDENTIFICAÇÃO DE *OUTLIERS*

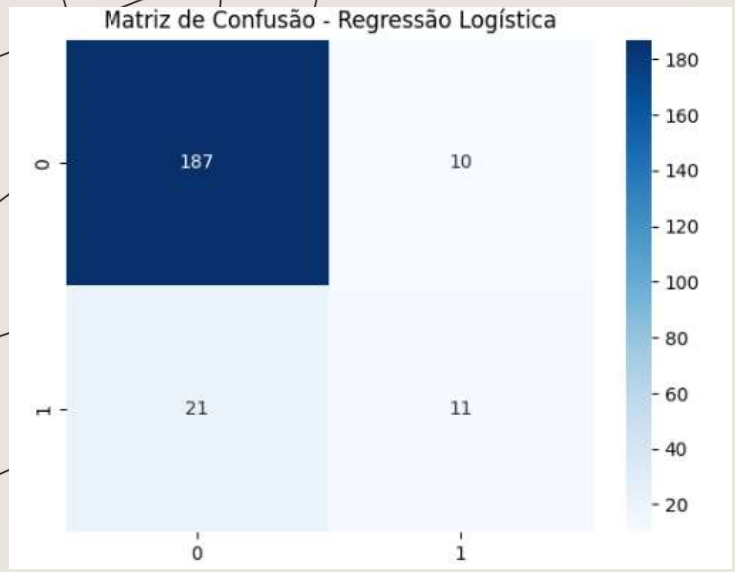








REGRESSÃO LOGÍSTICA



O modelo de Regressão Logística alcançou:

- **Accuracy:** 86,46%
- **Precision:** 52,38%
- **Recall:** 34,38%
- **F1-Score:** 41,59%
- **ROC AUC:** 84,18%

A matriz mostra:	
Situação	Quantidade
Verdadeiros Negativos (0→0)	187
Falsos Positivos (0→1)	10
Falsos Negativos (1→0)	21
Verdadeiros Positivos (1→1)	11

REGRESSÃO LOGÍSTICA

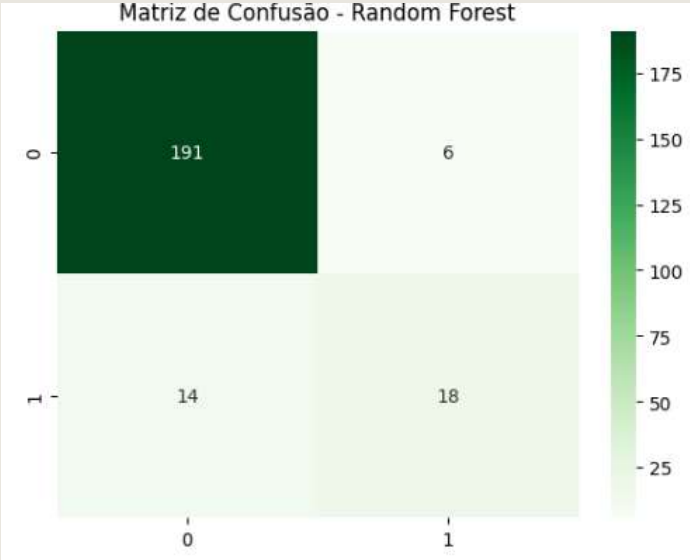
Dos **32 vinhos realmente classificados como alta qualidade**, o modelo identificou corretamente apenas **11**.

Além disso:

- Acertou 187 vinhos de baixa/média qualidade;
- Errou apenas 10 vinhos comuns classificando-os como alta qualidade;
- Deixou de identificar 21 vinhos que realmente eram de alta qualidade

O modelo apresentou uma boa capacidade de identificar vinhos de baixa e média qualidade. No entanto, apresentou limitações na identificação de vinhos de alta qualidade.

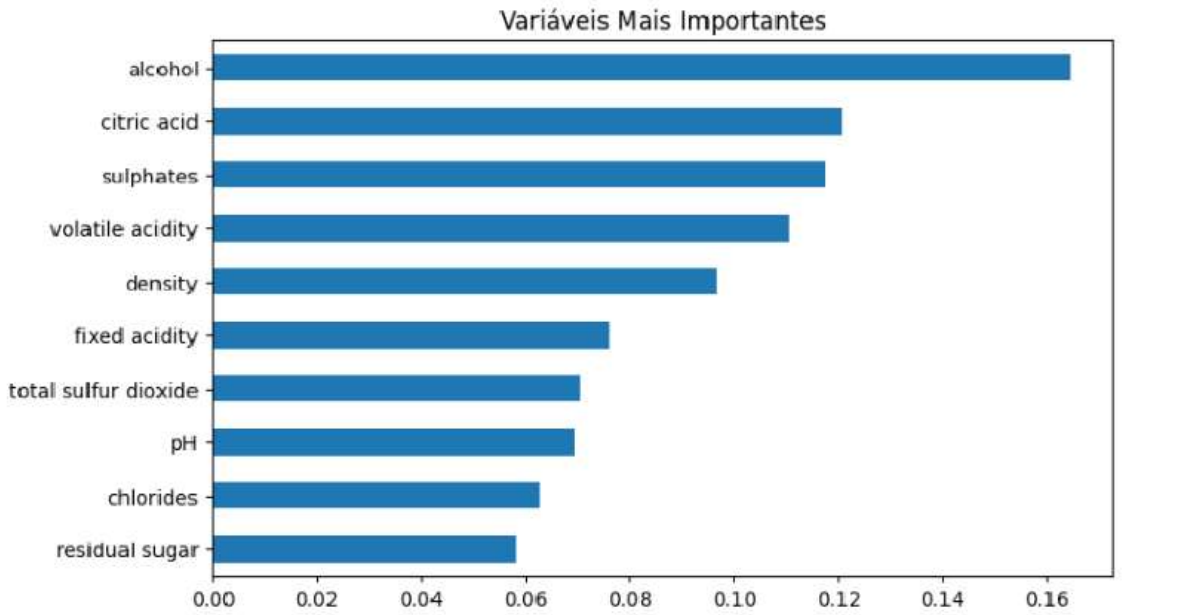
MATRIZ DE CONFUSÃO



Métrica	Resultado
Accuracy	91,27%
Precision	75,00%
Recall	56,25%
F1-Score	64,29%

O modelo Random Forest apresentou o melhor desempenho entre os modelos testados, destacando-se principalmente na identificação dos vinhos de alta qualidade. Com acurácia superior a 91% e melhor equilíbrio entre Precision e Recall, foi selecionado como o modelo final para a previsão da qualidade dos vinhos.

INFLUÊNCIA DAS VARIÁVEIS NA CLASSIFICAÇÃO DO PRODUTO



Principais Conclusões O modelo Random Forest apresentou melhor desempenho. O teor alcoólico foi uma das variáveis mais relevantes. A acidez volátil apresentou correlação negativa com a qualidade. Sulfatos e ácido cítrico contribuíram positivamente para classificação dos vinhos. O modelo pode auxiliar produtores na previsão da qualidade final do produto.

OBRIGADA